

# Отчёт по лабораторной работе №2

## Продвинутые методы оптимизации

### Содержание

|          |                                                      |          |
|----------|------------------------------------------------------|----------|
| <b>1</b> | <b>Постановка задачи</b>                             | <b>2</b> |
| <b>2</b> | <b>Интервальные elementary-функции</b>               | <b>2</b> |
| <b>3</b> | <b>Тестовые функции</b>                              | <b>2</b> |
| <b>4</b> | <b>Методы оптимизации</b>                            | <b>3</b> |
| 4.1      | Имитация отжига (Simulated Annealing) . . . . .      | 3        |
| 4.2      | Генетический алгоритм . . . . .                      | 3        |
| <b>5</b> | <b>Результаты исследования</b>                       | <b>3</b> |
| 5.1      | Сравнение на функциях лабы 1 (гладкие) . . . . .     | 3        |
| 5.2      | Сравнение на функциях лабы 2 . . . . .               | 5        |
| 5.3      | Устойчивость имитации отжига к случайности . . . . . | 5        |
| <b>6</b> | <b>Теоретическое объяснение</b>                      | <b>7</b> |
| <b>7</b> | <b>Заключение</b>                                    | <b>7</b> |

# 1. Постановка задачи

Цель работы – реализовать два стохастических метода оптимизации, не требующих непрерывности целевой функции, поверх типа ConstructiveNumber из лабораторной работы №1, протестировать их на функциях с разной степенью сложности (гладкая мультимодальная, гладкая с плоской периферией, разрывная) и сравнить со скоростью сходимости, числом вызовов функции и требуемой памятью методов лабы 1.

## 2. Интервальные elementary-функции

Тестовые функции этой лабы используют  $\cos$ ,  $\sin$ ,  $\exp$ ,  $\sqrt{\cdot}$ ,  $\text{round}$  – в лабе 1 такие функции не требовались (там были только  $+$ ,  $-$ ,  $\times$ ,  $/$ ), поэтому пришлось реализовать их интервальные версии.

**Монотонные функции** ( $\exp$ ,  $\sqrt{\cdot}$ ): интервальное расширение тривиально –  $f([a, b]) = [f(a), f(b)]$ , поскольку монотонность гарантирует, что экстремумы достигаются на границах.

$\cos$  и  $\sin$  **не монотонны** – нужно проверить, не попадает ли внутрь отрезка  $[a, b]$  точка экстремума (для  $\cos$  – максимум в точках  $2\pi k$ , минимум в  $\pi + 2\pi k$ ). Если попадает – результат обязан включать этот экстремум (1 или  $-1$ ), иначе интервал будет неверно узким. Если нет – достаточно  $\min/\max$  от значений на границах.  $\sin$  реализован через сдвиг фазы:  $\sin(x) = \cos(x - \pi/2)$ .

$\text{round}$  **разрывна** – интервальное расширение обязано быть *консервативным*: возвращает весь диапазон целых чисел, которые может дать округление любой точки внутри  $[a, b]$ .

## 3. Тестовые функции

| Функция     | Гладкость         | Основная сложность                                          |
|-------------|-------------------|-------------------------------------------------------------|
| Rastrigin-2 | гладкая           | $\approx 400$ локальных минимумов на $[-5.12, 5.12]^2$      |
| Ackley-2    | гладкая           | почти нулевой градиент на периферии                         |
| Desmos      | <b>не гладкая</b> | разрывы из-за $\text{round}(\cdot)$ , градиент не определён |

Таблица 1: Тестовые целевые функции лабы 2

$$f_{\text{Rastrigin}}(x, y) = 20 + x^2 - 10 \cos(2\pi x) + y^2 - 10 \cos(2\pi y) \quad (1)$$

$$f_{\text{Ackley}}(x, y) = -20 \exp\left(-0.2 \sqrt{\frac{x^2 + y^2}{2}}\right) - \exp\left(\frac{\cos 2\pi x + \cos 2\pi y}{2}\right) + e + 20 \quad (2)$$

$$f_{\text{Desmos}}(x, y) = (x(\text{round}(\sin 10y) + 2) + y - 10)^2 + (x + (y(\text{round}(\sin 7x) + 2)))^2 - 7)^2 \quad (3)$$

Глобальный минимум всех трёх функций –  $f = 0$  в точке  $(0, 0)$  (для Desmos – приближённо).

## 4. Методы оптимизации

### 4.1. Имитация отжига (Simulated Annealing)

На каждом шаге пробуются случайный "сосед"  $y$  в радиусе  $\delta$  от текущей точки  $x^*$ . Если  $y$  лучше – переход происходит всегда. Если хуже – переход происходит с вероятностью Метрополиса:

$$p(x, y, t) = \exp\left(\frac{f(x) - f(y)}{t}\right) \quad (4)$$

Температура  $t$  постепенно остывает:  $t \leftarrow t \cdot \gamma$ ,  $\gamma < 1$ , на каждой итерации. Готовность иногда "ухудшиться" позволяет методу выбраться из локальных минимумов – пока температура высокая, такие переходы происходят часто; к концу работы метод становится разборчивее.

### 4.2. Генетический алгоритм

Поддерживается популяция из  $k$  точек. На каждом поколении:

1. **Отбор (selection)** – турнирный: берём случайных `tournament_size` особей, оставляем лучшую; повторяем  $r$  раз.
2. **Скращивание (crossover)** – новая особь = среднее арифметическое двух случайно выбранных родителей.
3. **Мутация** – с вероятностью `mutation_rate` к каждой координате потомка добавляется гауссов шум.

## 5. Результаты исследования

### 5.1. Сравнение на функциях лабы 1 (гладкие)

**Вывод:** на гладких функциях детерминированные методы (особенно градиентный спуск) существенно точнее ( $\sim 10^{-13}$  против  $\sim 10^{-1}$  у стохастических) при сопоставимом или меньшем числе вызовов функции – ожидаемо, поскольку градиентный спуск использует дополнительную информацию (производную).

| Функция       | Метод        | Итер. | func_calls | Время,с | Память | $f_{min}$             |
|---------------|--------------|-------|------------|---------|--------|-----------------------|
| QuadraticGood | Град.спуск   | 1625  | 1625       | 0.032   | 587 KB | $5.0 \times 10^{-13}$ |
| QuadraticGood | Нелдера-Мида | 230   | 374        | 0.013   | 56 KB  | $4.8 \times 10^{-9}$  |
| QuadraticGood | Имит.отжига  | 3000  | 3001       | 0.037   | 891 KB | $6.9 \times 10^{-2}$  |
| QuadraticGood | Генетич.алг. | 150   | 6040       | 0.166   | 34 KB  | $3.2 \times 10^{-4}$  |
| QuadraticBad  | Град.спуск   | 1536  | 1536       | 0.024   | 428 KB | $5.0 \times 10^{-13}$ |
| QuadraticBad  | Нелдера-Мида | 158   | 269        | 0.007   | 29 KB  | $1.3 \times 10^{-8}$  |
| QuadraticBad  | Имит.отжига  | 3000  | 3001       | 0.030   | 686 KB | $1.1 \times 10^{-1}$  |
| QuadraticBad  | Генетич.алг. | 150   | 6040       | 0.135   | 27 KB  | $1.8 \times 10^{-4}$  |
| Rosenbrock    | Град.спуск   | 20000 | 20000      | –       | –      | $4.8 \times 10^{-9}$  |
| Rosenbrock    | Нелдера-Мида | 223   | 392        | 0.007   | 35 KB  | $3.3 \times 10^{-9}$  |
| Rosenbrock    | Имит.отжига  | 3000  | 3001       | 0.024   | 471 KB | $4.96 \times 10^{-1}$ |
| Rosenbrock    | Генетич.алг. | 150   | 6040       | 0.128   | 25 KB  | $7.2 \times 10^{-1}$  |

Таблица 2: Сравнение всех 4 методов на функциях лабы 1




Рис. 1: Число вызовов функции по всем 4 методам на QuadraticGood.

## 5.2. Сравнение на функциях лабы 2

Градиентный спуск здесь неприменим в принципе – при попытке вызова метод возвращает `NotImplementedError` (аналитический градиент для этих функций сознательно не реализован).

| Функция     | Метод             | Итераций | func_calls | $f_{min}$ |
|-------------|-------------------|----------|------------|-----------|
| Rastrigin-2 | Нелдера-Мида      | 45       | ~90        | 4.97      |
| Rastrigin-2 | Имитация отжига   | 5000     | 5001       | 0.022     |
| Rastrigin-2 | Генетический алг. | 200      | 8040       | 0.00003   |
| Ackley-2    | Имитация отжига   | 5000     | 5001       | 0.023     |
| Ackley-2    | Генетический алг. | 200      | 8040       | 0.00035   |
| Desmos      | Нелдера-Мида      | 133      | ~260       | 0.042     |
| Desmos      | Имитация отжига   | 5000     | 5001       | 26.6      |
| Desmos      | Генетический алг. | 200      | 8040       | 0.00027   |

Таблица 3: Сравнение методов на функциях лабы 2

**Ключевое наблюдение:** метод Нелдера-Мида мгновенно застревает на Растригине (45 итераций, далеко от глобального минимума) – классическая ловушка локального метода на мультимодальной функции с ~400 ямами. Генетический алгоритм стабильно находит глобальный минимум на всех трёх функциях, включая недифференцируемую Desmos.

## 5.3. Устойчивость имитации отжига к случайности

Запустили имитацию отжига на Rastrigin-2 десять раз с разными seed.




Рис. 2: Только 2 из 10 запусков (20%) нашли глобальный минимум – остальные застряли в одном из соседних локальных минимумов.




Рис. 3: Сходимость SA (шумная траектория, постоянные колебания) и GA (плавная, быстрая сходимость за ~150–200 поколений).

## 6. Теоретическое объяснение

Имитация отжига исследует пространство **одной точкой** – если эта точка попадает в область притяжения локального минимума после того, как температура уже остыла, шанс выбраться оттуда стремится к нулю. Генетический алгоритм одновременно поддерживает **целую популяцию** точек – даже если большинство особей застревает в разных локальных минимумах, скрещивание между разными “удачными” особями может дать потомка ближе к глобальному минимуму. Это структурное преимущество популяционного поиска особенно заметно на функциях с большим числом локальных минимумов (Растрингин) – SA имеет только один шанс не застрять, GA – сразу несколько параллельных попыток.

С другой стороны, GA требует существенно больше вызовов функции на итерацию (весь размер популяции на каждое поколение), что видно и в таблицах, и на графике сравнения – это плата за более широкое исследование пространства.

## 7. Заключение

Детерминированные методы лабы 1 эффективнее там, где применимы (гладкие функции с известным градиентом или простой унимодальной структурой) – дают существенно более точный результат при сопоставимых затратах. Стохастические методы лабы 2 необходимы там, где детерминированные неприменимы или ненадёжны: недифференцируемые функции и функции с большим числом локальных минимумов. Среди двух стохастических методов генетический алгоритм оказался надёжнее имитации отжига на всех трёх тестовых функциях этой лабы – ценой большего числа вызовов функции на итерацию.